ScopeBot ภาพรวมการทำงานของระบบ

เอกสารต้นฉบับสำหรับนำเข้า Canva และจัดทำสไลด์นำเสนอ

ระบบ AI Chatbot สำหรับองค์กรที่ตอบคำถามจากเอกสารด้วย RAG รองรับ Web, LINE และการส่งต่อเจ้าหน้าที่

สิ่งที่นำเสนอรอบนี้

- ภาพรวมระบบและขอบเขตการทำงาน
- Diagram แยก Frontend Backend Database และ AI
- Timeline การพัฒนา
- Demo ระบบตามลำดับการใช้งานจริง

ผลลัพธ์ที่ผู้ฟังควรเข้าใจ

- ส่วนประกอบหลักเชื่อมต่อกันอย่างไร
- ข้อมูลและเอกสารไหลผ่านระบบอย่างไร
- กรณี AI ตอบไม่ได้ส่งต่อเจ้าหน้าที่อย่างไร
- ระบบพร้อมสำหรับการทดลองใช้งานระดับใด

ขอบเขตการนำเสนอรอบนี้

ใช้ Diagram เป็นแกนหลักและอธิบายเฉพาะสิ่งที่มีอยู่จริงในระบบ

ช่วง	ประเด็น	สิ่งที่จะสื่อ
1	System Overview	ผู้ใช้ ช่องทาง ระบบเว็บ API ฐานข้อมูล AI และ deployment
2	Architecture	แยก Frontend Backend Database RAG และ Integration
3	Timeline	พัฒนาจากระบบสนทนาไปสู่ RAG LINE live support และ pilot readiness
4	Demo	Login เลือกบอท ถามคำถาม แสดงแหล่งอ้างอิง และส่งต่อเจ้าหน้าที่
5	Q and A	ข้อจำกัด การติดตั้ง ความปลอดภัย และสิ่งที่ต้องเตรียมก่อนใช้งาน

ข้อควรระวังในการนำเสนอ

- ไม่กล่าวอ้างความแม่นยำ เวลาในการตอบ หรือจำนวนผู้ใช้ หากยังไม่มีผลทดสอบรองรับ
- ไม่กล่าวว่ามี SSO MFA WAF หรือระบบสำรองข้อมูลอัตโนมัติ เพราะยังไม่ยืนยันจากโค้ด
- ใช้ข้อมูลตัวอย่างที่ไม่ระบุตัวบุคคลระหว่าง Demo

ภาพรวมการทำงานของ ScopeBot

จากเอกสารองค์กรสู่คำตอบที่มีแหล่งอ้างอิงและส่งต่อคนได้เมื่อจำเป็น

Knowledge Flow

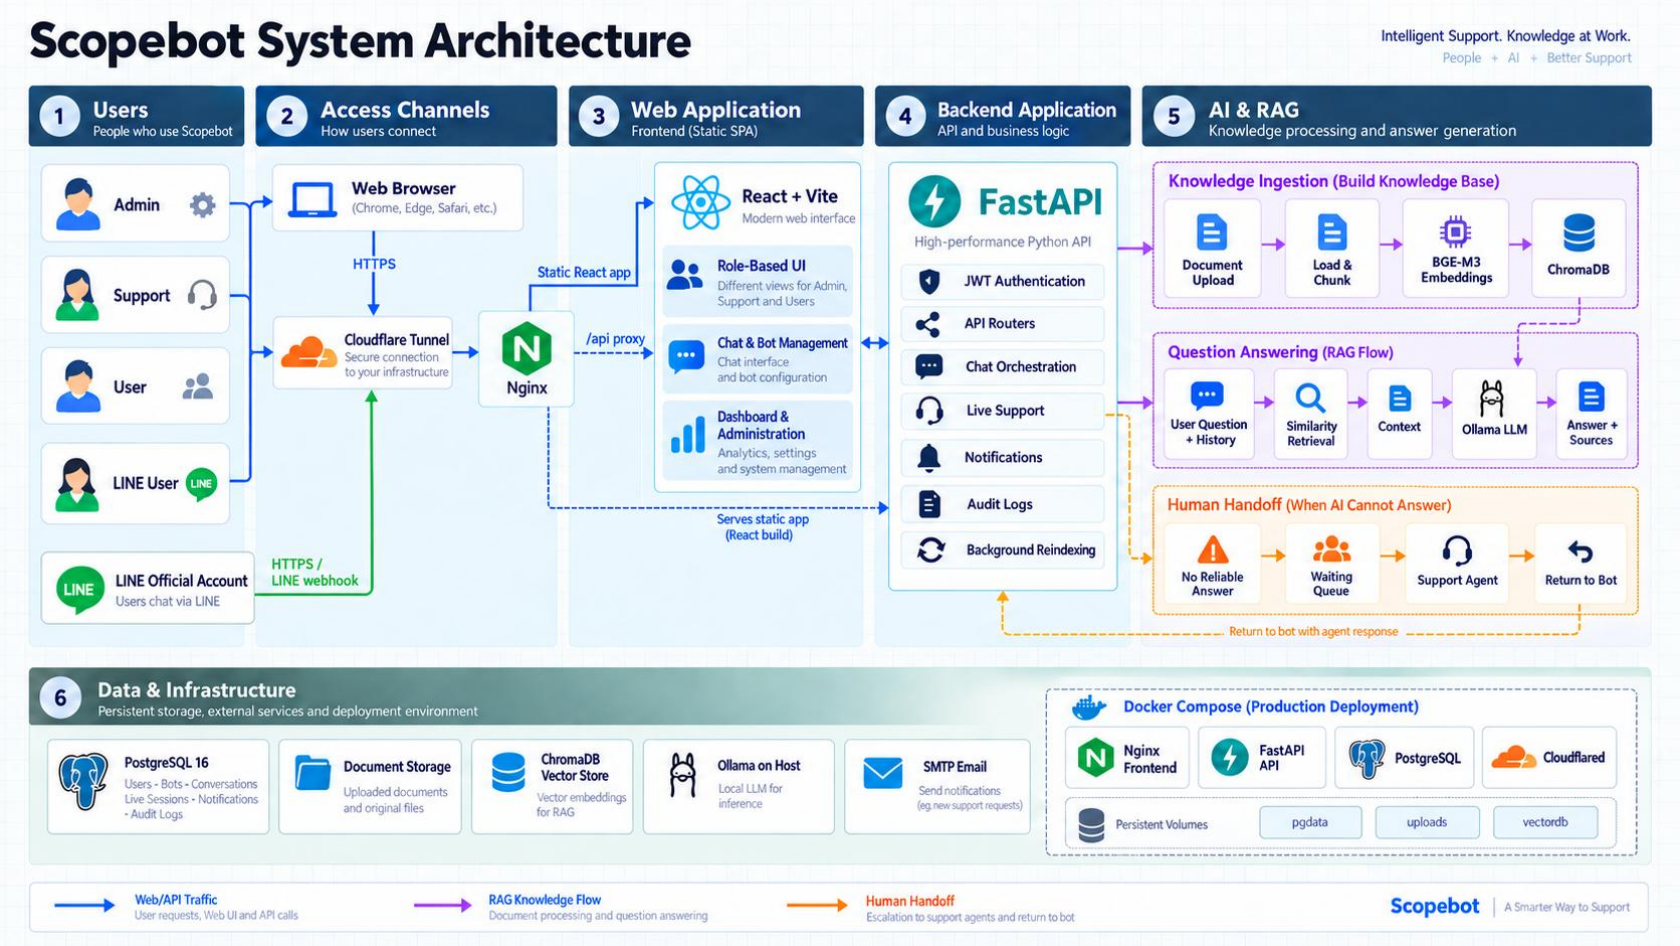
- ผู้ดูแลอัปโหลด PDF DOCX TXT หรือ CSV
- ระบบอ่านและแบ่งเอกสารเป็นส่วนย่อย
- BGE M3 สร้าง embeddings และบันทึกใน ChromaDB แยกตามบอท
- คำถามค้นหาเฉพาะเนื้อหาที่เกี่ยวข้อง
- Ollama สร้างคำตอบและส่งชื่อไฟล์กับข้อความอ้างอิงกลับไป

Service Flow

- ผู้ใช้เริ่มจาก Web หรือ LINE
- FastAPI ตรวจสิทธิ์และจัดเส้นทางคำขอ
- บันทึกประวัติการสนทนาใน PostgreSQL
- หากไม่พบคำตอบ ผู้ใช้เลือกติดต่อเจ้าหน้าที่
- เจ้าหน้าที่ตอบผ่าน Live Chat แล้วปิด session เพื่อกลับสู่ Bot Mode

System Architecture Diagram

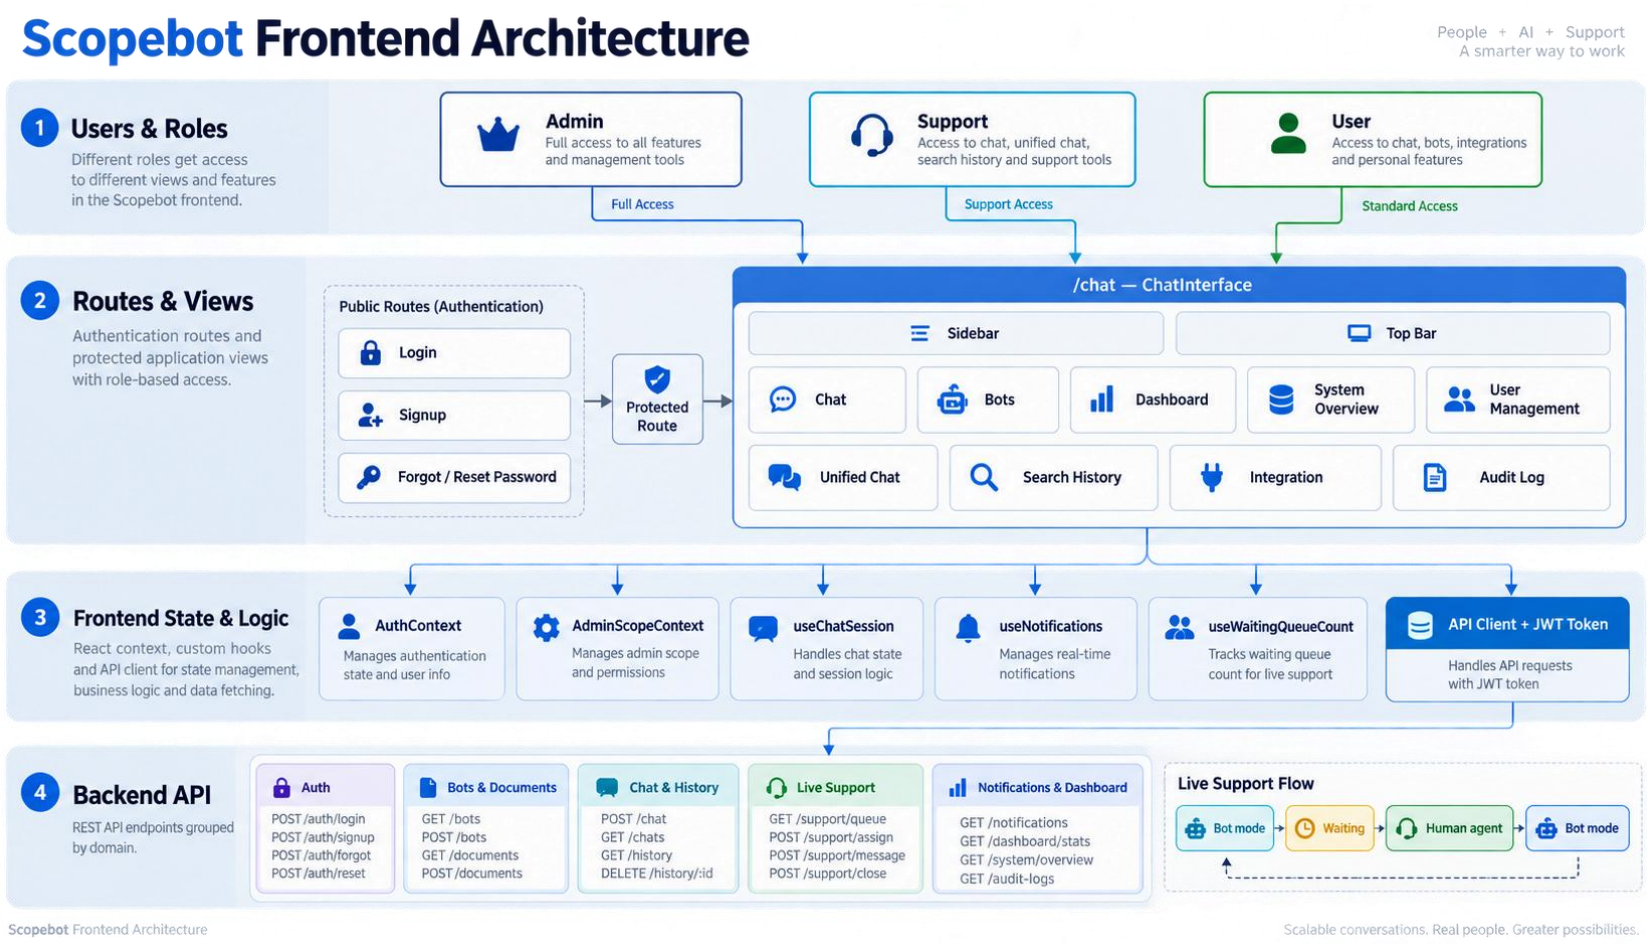
ภาพรวม Web LINE Frontend Backend AI Data และ Deployment



เส้นสีน้ำเงินแสดง Web และ API traffic สีม่วงแสดง RAG flow และสีส้มแสดง Human handoff

Frontend Architecture

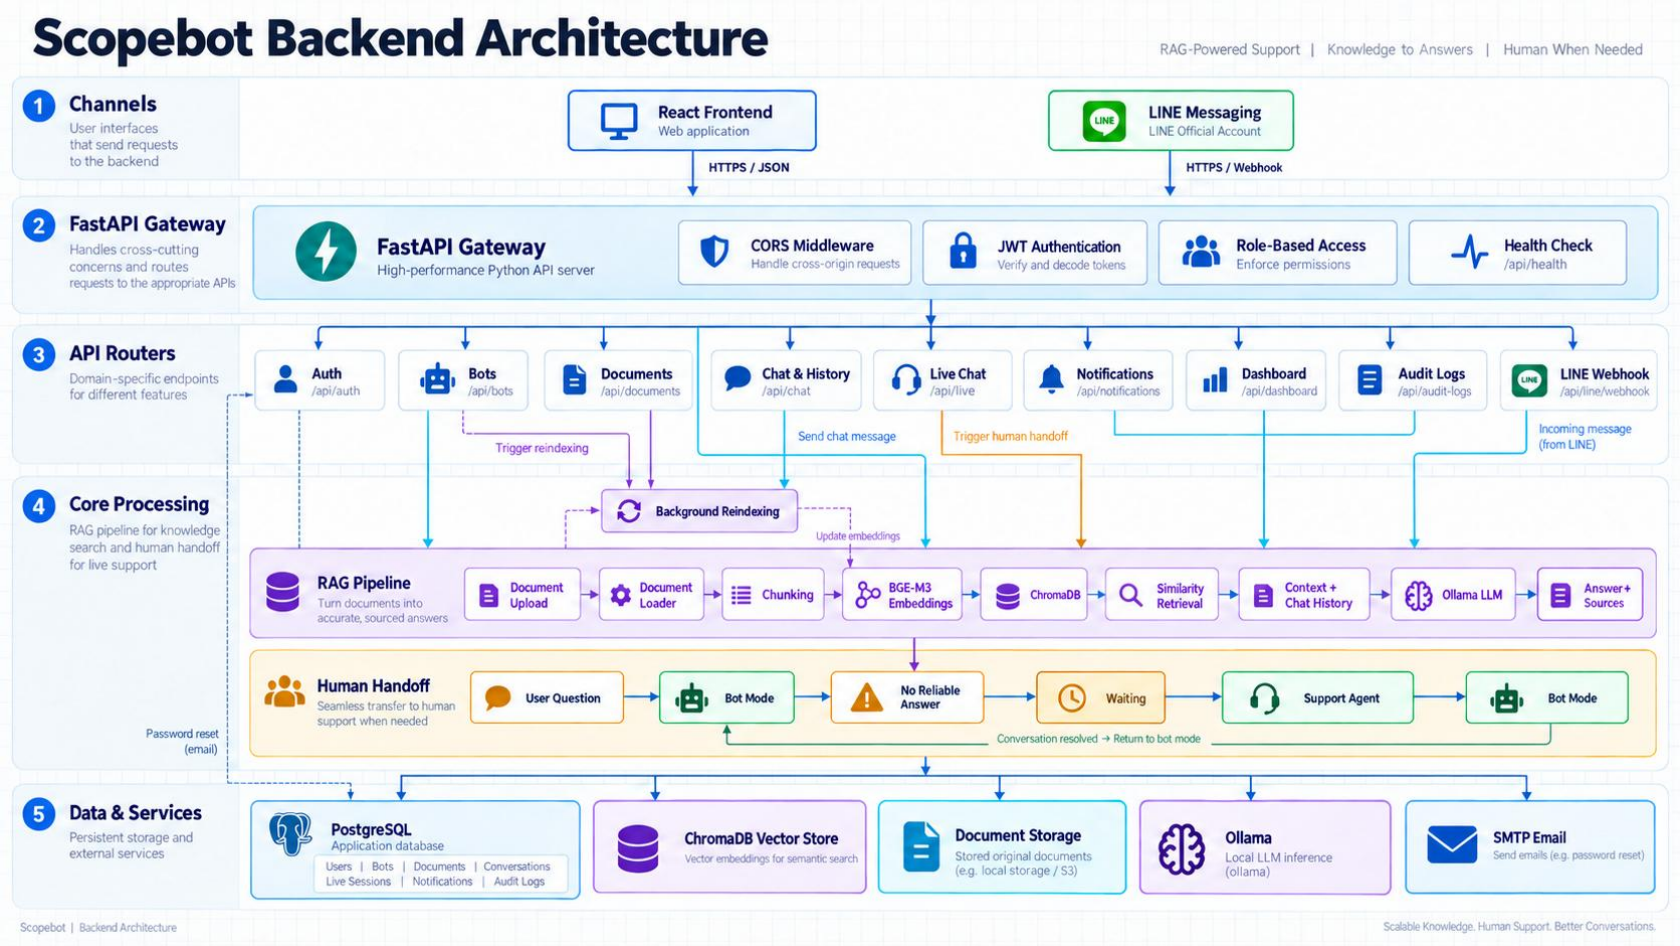
React application ที่ปรับมุมมองตามบทบาทและรวมทุกฟังก์ชันไว้ใน ChatInterface



ผู้ใช้แต่ละบทบาทเข้าถึง view ต่างกัน โดย Context และ Hooks จัดการสถานะก่อนเรียก Backend API

Backend Architecture

FastAPI เชื่อม business APIs กับ RAG ฐานข้อมูล และ human handoff



Backend แยก router ตามโดเมน และเชื่อม PostgreSQL ChromaDB Ollama Document Storage และ SMTP

Database และข้อมูลหลัก

PostgreSQL เป็นฐานข้อมูลธุรกรรม ส่วน ChromaDB เก็บเวกเตอร์ความรู้แยกตามบอท

กลุ่มข้อมูล	Entity หลัก	หน้าที่
Identity	users password_reset_tokens	บัญชี บทบาท การอนุมัติ และการรีเซ็ตรหัสผ่าน
Bot Knowledge	bots documents bot_documents	เจ้าของบอท เอกสาร และความสัมพันธ์แบบ many to many
Conversation	conversations	คำถาม คำตอบ แหล่งช่องทาง และสถานะการตอบ
Human Support	live_sessions live_messages	session แบบ bot waiting human และข้อความจากทุกฝ่าย
Operations	notifications audit_logs	การแจ้งเตือนและประวัติการดำเนินการของผู้ดูแล
Vector Knowledge	ChromaDB per bot	embedding ของ document chunks สำหรับ similarity retrieval

ความสัมพันธ์สำคัญ User 1 ต่อหลาย Bot User 1 ต่อหลาย Document Bot หลายต่อหลาย Document Bot 1 ต่อหลาย Conversation และ LiveSession

AI RAG Pipeline

คำตอบใช้เอกสารที่ค้นพบเป็นแหล่งข้อเท็จจริงและใช้ประวัติเพื่อเข้าใจคำถามต่อเนื่อง

ขั้นตอน	การทำงาน	ค่าหรือเทคโนโลยี
1 Upload	รับเอกสารและผูกกับบอท	PDF DOCX TXT CSV สูงสุด 10 MB
2 Process	Load และแบ่งเนื้อหาเป็น chunks	chunk 1000 overlap 200
3 Embed	แปลงข้อความเป็นเวกเตอร์	BAAI bge m3
4 Store	บันทึก knowledge index	ChromaDB แยก directory ตาม bot id
5 Retrieve	ค้นหา chunks ที่ใกล้คำถาม	TOP K 5 และกรอง distance threshold
6 Generate	ประกอบ context และเรียก LLM	Ollama ค่าเริ่มต้น qwen2.5 1.5b
7 Respond	คืนคำตอบและแหล่งอ้างอิง	ชื่อไฟล์และ snippet สูงสุด 3 แหล่ง

Live Chat และ LINE Integration

ระบบแยกเส้นทางคำตอบปกติออกจากเส้นทางส่งต่อเจ้าหน้าที่

LINE Normal Flow

- LINE User ส่งข้อความเข้า LINE Platform
- Webhook รับ event ที่ /api/line/webhook/{bot_id}
- ตรวจ X Line Signature ด้วย channel secret
- บันทึกข้อความและเรียก RAG
- ตอบผ่าน reply message หรือ push message

Human Handoff Flow

- RAG ไม่พบคำตอบที่เชื่อถือได้ หรือผู้ใช้ขอเจ้าหน้าที่
- สร้างหรือปรับ LiveSession เป็น waiting
- แจ้งเตือน Support และแสดงคิวในระบบ
- เจ้าหน้าที่ตอบครั้งแรก Session เปลี่ยนเป็น human
- เมื่อปิด Session ระบบกลับสู่ bot และสนทนาต่อได้

Bot Mode → Waiting → Human Agent → Bot Mode

Timeline การพัฒนา

สรุป milestone จากประวัติการเปลี่ยนแปลงใน repository

ช่วงเวลา	Milestone	ผลลัพธ์
พฤษภาคม 2026	Chat UI และการจัดการผู้ใช้	ChatInterface Bot page User management Dashboard และ Chat history
กรกฎาคม 2026	Database และ Deployment	ปรับฐานข้อมูล เพิ่ม Docker พัฒนาบอท Dashboard และ LINE webhook
กันยายน 2026	Roles UI และความเสถียร	ปรับ role และเมนู รองรับชนิดไฟล์ แก้บัคบอทและการลบเอกสาร
กันยายน 2026	Audit และ Pilot Readiness	เพิ่ม Audit log ชุดทดสอบ smoke test และ production checklist
รอบปัจจุบัน	Architecture และ Demo	จัดทำ diagram ภาพรวม เตรียมเส้นทาง demo และแบ่งผู้พูด

ข้อความสำหรับพูด ระบบพัฒนาเป็นลำดับจากหน้าจอสนทนาและการจัดการผู้ใช้ ไปสู่ฐานข้อมูล การเชื่อมต่อ LINE การควบคุมสิทธิ์ และความพร้อมสำหรับการทดลองใช้งาน

Demo ระบบ

ใช้ข้อมูลตัวอย่างที่เตรียมไว้และเดินตามเส้นทางเดียวตั้งแต่ต้นจนจบ

ลำดับ	หน้าจอหรือการกระทำ	สิ่งที่อธิบาย	แผนสำรอง
1	Login	บทบาทและ Protected Route	ใช้บัญชี Demo ที่ตรวจแล้ว
2	Bots	เลือกบอทและดูสถานะเอกสาร	เตรียมบอท Active ล่วงหน้า
3	Chat	ถามคำถามจากเอกสาร	เตรียมคำถามที่ทดสอบแล้ว 2 ข้อ
4	Sources	แสดงชื่อไฟล์และ snippet อ้างอิง	ใช้ screenshot หาก Ollama ช้า
5	Handoff	กดติดต่อเจ้าหน้าที่และดู Waiting Queue	เปิดบัญชี Support ไว้อีกหน้าต่าง
6	Support Reply	เจ้าหน้าที่ตอบและจบ session	เตรียม session สำรอง
7	Dashboard Audit	ภาพรวมสถิติและประวัติการจัดการ	ใช้ข้อมูล seed ที่ไม่ระบุตัวบุคคล

การแบ่งผู้พูดและ Checklist

กรอกชื่อก่อนวันนำเสนอและซ้อมการส่งต่อระหว่างผู้พูด

ช่วงนำเสนอ	ผู้พูด	เวลาประมาณ	ประโยคส่งต่อ
เปิดเรื่องและ System Overview	[กรอกชื่อ]	2 นาที	ต่อไปจะอธิบายส่วนประกอบของระบบแต่ละชั้น
Frontend Backend Database RAG	[กรอกชื่อ]	5 นาที	จากโครงสร้างระบบ ต่อไปเป็นลำดับการพัฒนา
Timeline	[กรอกชื่อ]	2 นาที	เพื่อให้เห็นการทำงานจริง ต่อไปเป็นการสาธิตระบบ
Demo	[กรอกชื่อ]	5 นาที	จบการสาธิตแล้ว พร้อมรับคำถาม
Q and A	[กรอกชื่อ]	ตามเวลา	สรุปคำตอบและประเด็นติดตาม

Checklist ก่อนนำเสนอ

- ตรวจรายชื่อผู้เข้าร่วมและผู้พูดแต่ละช่วง
- ทดสอบ Web API PostgreSQL Ollama และ LINE webhook
- เตรียมเอกสารตัวอย่าง บอท Active และคำถาม Demo
- เปิดบัญชี User และ Support แยกหน้าต่าง
- เตรียม screenshot หรือวิดีโอสำรองกรณีเครือข่ายหรือโมเดลช้า